



POLITECHNIKA WROCŁAWSKA

SIECI NEURONOWE I NEUROSTEROWNIKI

Sprawozdanie z projektu

Michał Leś, Jędrzej Kozal

prowadzący
Dr inż. Piotr CISKOWSKI

2017-10-01

1 Wstęp

Podstawowym założeniem projektu jest zaznajomienie się z neurosterownikami, ich zasadami działania oraz przygotowanie modelu predykcyjnego prostego obiektu dynamicznego. Dodatkowo przyjęto że bardziej interesujące będzie przyjęcie jakiegoś rzeczywistego obiektu niż badanie reakcji bardziej teoretycznego modelu o przyjętych charakterystykach.

Neurosterowniki są sposobem zaadresowania w Automatyce kwestii sterowania obiektami mocno nieliniowymi, z którymi tradycyjne metody sterowania jak sterowniki PID nie dają sobie rady. U podstaw działania neurosterowników leży idea działania sieci neuronowej, które ostatnio zdominowały pole uczenia maszynowego. Są one wykorzystywane w wielu dziedzinach nauki i techniki do rozpoznawania obrazów (computer vision), klasyfikacji, sterownia ruchem ulicznym, wspomagania użytkowników różnych aplikacji (jak np. podpowiadanie słów w trakcie pisania na smartphonie), czy nawet prowadzenie eksperymentów społecznych. W niniejszej pracy postawiono zbadać w jaki sposób szerokie możliwości oferowane przez sieci neuronowe mogą być wykorzystane w automatyce.

2 Podstawy teoretyczne

2.1 Przyjęty model obiektu

Obiekt w automatyce jest traktowany jako czarna skrzynka, która posiada wejścia i wyjścia. Na pobudzenie na wejściu reaguje odpowiedzią na wyjściu. Odpowiedź systemów dynamicznych zależy nie tylko od aktualnej wartości wejścia, ale także stanu obiektu w poprzednich chwilach. Zgodnie z tym można zapisać model nieliniowego dyskretnego obiektu dynamicznego jako:

$$\begin{cases} \mathbf{x}(k+1) &= \phi(\mathbf{x}(k), \mathbf{u}(k)) \\ \mathbf{y}(k) &= \psi(\mathbf{x}(k)) \end{cases} \quad (1)$$

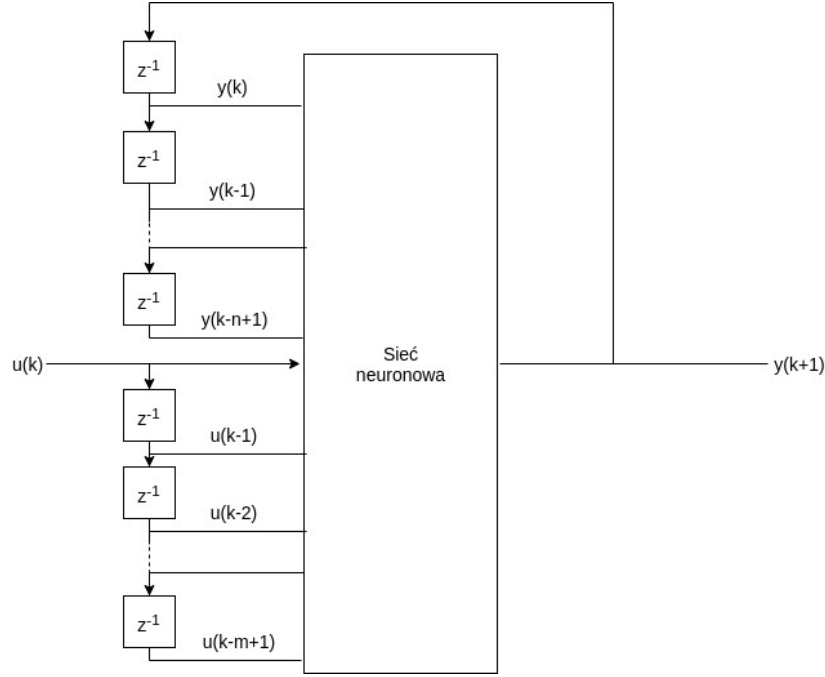
Układ równań 1 przedstawia równania stanu. Pierwsze równanie wiąże wewnętrzny stan obiektu z pobudzeniem, a drugie równanie wiąże stan obiektu z wyjściem. System opisywany tymi równaniami jest niezmienny w czasie (angl. time-invariant) - ϕ i ψ nie zależą bezpośrednio od czasu.

Jeśli zastąpimy funkcje nieliniowe przez odpowiednie macierze zyskamy system liniowy:

$$\begin{cases} \mathbf{x}(k+1) &= A\mathbf{x}(k) + B\mathbf{u}(k) \\ \mathbf{y}(k) &= C\mathbf{x}(k) + D\mathbf{u}(k) \end{cases} \quad (2)$$

W rzeczywistych systemach w równaniach oprócz stanu \mathbf{x} i pobudzenia \mathbf{u} pojawiają się także zakłócenia \mathbf{z} , które nie będą tutaj rozważane.

Klasa systemów liniowych jest od dawna dobrze znana. Znaleziono wiele sposobów badania i algorytmów sterowania obiektami liniowymi. O wiele trudniejsze w sterowaniu są obiekty nieliniowe. Nawet znając funkcję ψ oraz $x(k)$ samo stworzenie modelu mogącego dokonać identyfikacji takiego obiektu jest



Rysunek 1: Model identyfikacji obiektu z wykorzystaniem sieci neuronowej.

trudne, ze względu na kumulujące się z czasem błędy numeryczne, oraz poprzez konieczność poczynienia założeń co do stabilności systemu.

Najprostsza reprezentacja systemu dynamicznego nie zawiera wewnętrznego stanu, który w wielu wypadkach może być pominięty

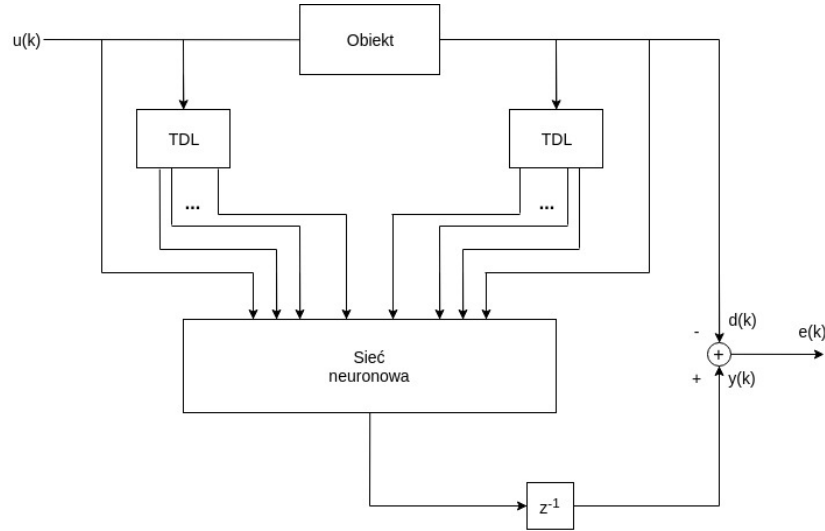
$$\mathbf{y}(k+1) = f(\mathbf{y}(k), \mathbf{u}(k)) \quad (3)$$

2.2 Zadanie identyfikacji obiektu

Zadanie identyfikacji sprowadza się do wyznaczeniu modelu reagującego na pobudzenie w sposób zbliżony do reakcji rzeczywistego obiektu:

$$\|\hat{y} - y\| < \epsilon \quad (4)$$

Uzyskanie takiego modelu umożliwia sterowanie adaptacyjne, co znacznie ułatwia pracę z obiektami nieliniowymi. Celem sterowania w ogólności jest uzyskanie na wyjściu obiektu $\mathbf{y}(k)$ wartości jak najbardziej zbliżonej do wartości zadanej $\mathbf{y}_m(k)$. W przypadku sterowania adaptacyjnego oznacza to znalezienie takiego pobudzenia $\mathbf{u}(k)$ aby została spełniona zależność:



Rysunek 2: Schemat podłączenia sieci neuronowej w trakcie uczenia.

$$\lim_{k \rightarrow \infty} \|\mathbf{y}(k) - \mathbf{y}_m(k)\| < \epsilon \quad (5)$$

Często do takiego zadania są wykorzystywane sieci neuronowe przedstawione na rys. 1. Na wejście sieci podaje się wejścia systemu, oraz wyjścia z poprzednich chwil. Zadaniem sieci jest przewidzenie zachowania systemu w kroku $k+1$. Szereg bloków opóźniających będzie dalej oznaczany w pracy jako TDL (Tapped Delay Line).

W trakcie identyfikacji sieć neuronowa jest zwykle włączana sposob szeregowo-równoległy, co zostało zilustrowane na rys 2. Taka konfiguracja umożliwia badanie błędu i minimalizację błędu zgodnie z nierównością 4. Sieć neuronowa nieustannie próbuje przewidzieć wyjście obiektu w następnej chwili. Różnica $e(k)$ jest wykorzystywana w procesie uczenia sieci. W [1] zaproponowano taką metodę oraz zaprezentowano wykorzystanie modelu do predykcji wyjścia filtru Butterwortha szóstego rzędu dla pobudzenia sygnałem trójkątnym oraz tłumionym sygnałem sinusoidalnym.

3 Zrealizowane zadania oraz otrzymane wyniki

4 Wnioski

Literatura

- [1] Stanisław Osowski. *Sieci Neuronowe w ujęciu algorytmicznym* Wydawnictwo Naukowo-Techniczne, Warszawa 1996
- [2] Strona prowadzącego,
<http://staff.iiar.pwr.wroc.pl/piotr.ciskowski/skrypt/SNwMATLABie.htm>
- [3] J. Rhim, S. W. Lee *A neural network approach for damage detection and identification of structures* Computational Mechanics, Springer 1995
- [4] Jerzy Lipski *Identyfikacja procesów dynamicznych z zastosowaniem sieci neuronowych* Nauka i technika 2001